

# 第5回 GNN勉強会

## 様々なタスクの応用 4.1, 4.2章

---

山口大学大学院  
創成科学研究科 平井元基  
2024/08/04

# 今回のゴール

## 今回のゴール

- GNNにおけるグラフ分類問題を定量的かつ定性的に理解をする。

## 学習手順

今回は、以下の図 1に示すような 3ステップでの学習を行います。

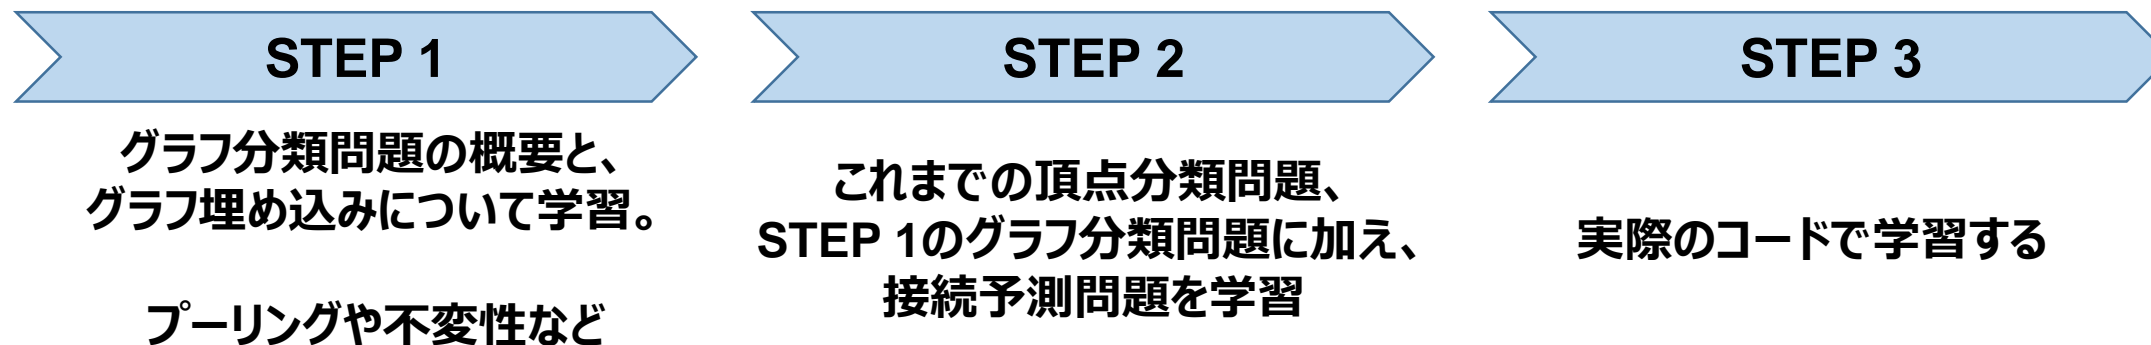


図1 第5回GNN勉強会におけるフロー図

# 参考書

## 今回使用するテキスト

佐藤 竜馬, “グラフニューラルネットワーク,”  
講談社, 2024, 5月, 第1版, 第2印.

<https://amzn.asia/d/hMovaf4>

## 各種リンク

GitHub リポジトリ:

<https://github.com/joisino/gnnbook.git>

先生の自己紹介サイト

<https://joisino.net/>



**STEP 1**

## **4.1 グラフ分類**


## 4.1.1 グラフ分類問題の解き方

### グラフ分類問題とは

- グラフ全体をクラスごとに分類する問題のこと。  
（例：化合物の毒性や効果の有無で分類、感情分析、画像分類、など）

### 具体的手法

- 大きく二つの手法が存在。
  - ① グラフプーリング（Graph Pooling）を用いる方式
  - ② 超頂点（supernode）を用いる方式



## 4.1.1 グラフ分類問題の解き方 -2

### 頂点分類問題とグラフ分類問題の比較

表1 頂点分類問題とグラフ分類問題の比較

GNNのタスク	頂点分類問題	グラフ分類問題
概要	グラフノードの分類	グラフそのものを分類
応用例	ユーザ分類、 画像のセグメンテーションなど	毒性予測、 画像分類など
学習手法	転導的学習、 帰納的学習	グラフプーリングの使用、 超頂点の使用

## 4.1.1 グラフ分類問題の解き方 -3

### グラフプーリング

表2 グラフプーリング手法の比較

プーリングの種類	プーリングにおける数式
平均プーリング	$\mathbf{z}_G = \frac{1}{n} \sum_{v \in V} \mathbf{z}_v$
最大プーリング	$\mathbf{z}_G = \max(\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_n)$
頂点ごとに重みを調整	$\mathbf{z}_G = \tanh \left( \sum_{v \in V} \sigma(f(\mathbf{z}_v, \mathbf{x}_v)) \odot \tanh(g(\mathbf{z}_v, \mathbf{x}_v)) \right)$
Transformer	$\mathbf{z}_G = \text{Transformer}(\{\{\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_n, [CLS]\}\})[CLS]$

## 4.1.1 グラフ分類問題の解き方 -4

### 超頂点 (supernode) とは

- 図 1のように、グラフの前処理手法の一つで、グラフに対し便宜的に導入するノードのこと。
- グラフ内のすべてのノードの情報を考慮して、一つのノードとして埋め込む。

### 超頂点の利点

- ノード数が異なるグラフ間の比較が容易となる。




図2 超頂点の概略図



## 4.1.2 不変性

### 不変 (invariant) とは

- グラフ埋め込み手法が不変 (invariant) とは、同型グラフに対し、同じグラフ埋め込み手法を行うこと。
- 同変性 (3.5章参照) の埋め込み版。

#### 定義 4.2 (不変性)

グラフを受けとりグラフ埋め込み集合を返す関数

$$g : (V, E, X) \mapsto \mathbf{z} \in \mathbb{R}^d$$

が不変であることは、任意の同型なグラフ  $G_1 = (V_1, E_1, X)$  と  $G_2 = (V_2, E_2, Y)$  について、

$$g(G_1) = g(G_2)$$

が成り立つことをいう。

ただし、 $V$  を頂点集合、 $E$  を辺集合、 $X, Y$  を頂点特徴量、 $\mathbf{z}$  を埋め込みベクトルとする。

## 4.1.2 不変性 -2

### 不変を意識したプーリング（埋め込み）のメリット

- 解釈が容易  
（どのように予測したかが、直感的にわかりやすい）
- よい帰納バイアスをもつ  
（汎化性能が向上しやすい）

### 不変性のないプーリング手法

LSTMは系列の順番が重要なため、不変性をもたない

**STEP 2**

## **4.2 接続予測**

## 4.2 接続予測

### これまでの問題と接続予測問題の比較

表3 頂点分類問題とグラフ分類問題、および接続予測問題の比較

GNNのタスク	頂点分類問題	グラフ分類問題	接続予測問題
概要	グラフノードの分類	グラフそのものを分類	グラフの辺（エッジ）を予測
応用例	ユーザ分類、 画像のセグメンテーションなど	毒性予測、 画像分類など	推薦システム、 （新規の）ユーザ予測、など
学習手法	転導的学習、 帰納的学習	グラフプーリングの使用、 超頂点の使用	頂点埋め込みの対の使用、 グラフ分類に帰着する手法

## 4.2 接続予測 -2

### 頂点埋め込みの対を用いる方法

- まず頂点埋め込み  $\mathbf{z}_v, \mathbf{z}_u$  を求め、埋め込みをもとに辺の有無を予測

### 具体的な学習手法

【例】

埋め込みの内積  $\mathbf{z}_v^T \mathbf{z}_u$  が最も大きいときに辺が存在すると予測する手法

- ① 訓練時にはシグモイド関数を用い、 $\sigma(\mathbf{z}_v^T \mathbf{z}_u) \in (0, 1)$  を辺の存在確率とする。
- ② クロスエントロピー損失で学習。
- ③ テストデータにおける埋め込みベクトルの内積から、二値分類的に辺の有無を予測。

## 4.2 接続予測 -3


### グラフ分類に帰着する方法

- 予測したい頂点の対  $u, v$  について、 $u, v$  の周りのグラフを切り出し、切り出したグラフを正例・負例として分類して辺の有無を予測

### 具体的な学習手法

【例】

$u, v$  のいずれかから  $K$  本以下の辺を用いてグラフを切り出す手法  
(図4.2[テキストより引用] 参考)



## 4.2 接続予測 -4

### 頂点予測問題における注意点

- データリークが起こりやすい
  - 時系列のデータ
  - モデルに入力するグラフと、学習に使用する辺の混同
- 辺（グラフ）を観測できないことがある
  - 例えば、学習予定のグラフを訓練、評価、テストに分割し、十分に予測可能かをみる（予測できない場合、データに不具合がある）

**STEP 3**

**実際のコードを見る**